

Связь теории индуктивного вывода и программирования с помощью нейросетей

Основные тезисы

1. Простой запрос к нейросети — аналог генерации скелета с помощью JHipster:

- Запрос к большой языковой модели (LLM) для генерации кода выполняет роль «быстрого старта» — аналогично инструментам типа JHipster, которые создают базовый каркас приложения.
- В обоих случаях пользователь задаёт высокоуровневые требования (спецификацию), а система автоматически генерирует начальный код.
- Разница в том, что нейросети опираются на вероятностное моделирование (обучение на миллионах примеров), а генераторы кода — на жёстко заданные шаблоны.

2. Сложность дополнительных запросов равна колмогоровской сложности итогового ПО:

- Колмогоровская сложность $K(x)$ — это длина кратчайшей программы, которая выводит объект x и останавливается.
- Каждый дополнительный запрос к нейросети уточняет и дополняет генерируемый код. Совокупная сложность всех запросов (включая итерации, правки, уточнения) асимптотически приближается к $K(P)$, где P — итоговая программа.
- Формально: если $Q = \{q_1, q_2, \dots, q_n\}$ — последовательность запросов, то:

$$\sum_{i=1}^n |q_i| \approx K(P)$$

где $|q_i|$ — сложность (длина/информативность) i -го запроса.

3. Необходимость формальных тестов для избежания неоднозначностей:

- Естественный язык запросов к нейросетям неоднозначен. Одна и та же фраза может быть интерпретирована по-разному.
- Формальные тесты (unit-тесты, интеграционные тесты) задают однозначные критерии корректности. Они выполняют роль «наблюдаемых данных» D в индуктивном выводе.
- Без тестов генерация кода становится задачей с неполными данными, что ведёт к:
 - неполноте реализации,

- логическим ошибкам,
- уязвимостям безопасности.

4. Алгоритмическая сложность вывода минимальной программы:

- Задача найти минимальную программу $P_{\min}$, удовлетворяющую набору тестов T , алгоритмически неразрешима в общем случае (следствие теоремы о невычислимости $K(x)$).
- На практике это означает, что нейросеть не может гарантированно сгенерировать самый короткий и оптимальный код.
- Вместо этого она ищет «достаточно хорошую» аппроксимацию, часто добавляя избыточные конструкции или неоптимальные решения.

5. Пространство для нежелательных эффектов в сгенерированном коде:

- Из-за алгоритмической сложности и неполноты спецификаций в коде могут появляться:
 - скрытые уязвимости (например, SQL-инъекции, XSS),
 - неэффективные алгоритмы (квадратичная сложность вместо линейной),
 - мёртвый код и неиспользуемые зависимости,
 - побочные эффекты (side effects), нарушающие чистоту функций.
- Эти проблемы — прямое следствие того, что генерация кода по запросам есть индуктивный вывод, а не дедуктивный синтез.
- Для их минимизации необходимы:
 - строгие формальные тесты,
 - статический анализ кода,
 - ручной аудит критически важных участков.

Выводы

Программирование с помощью нейросетей реализует принципы индуктивного вывода:

- Запросы к нейросети задают априорные предположения о структуре кода.
- Тесты выполняют роль наблюдаемых данных D , уточняющих гипотезу.
- Итоговая программа — это апостериорная гипотеза $P(T \mid D)$, максимизирующая правдоподобие при заданных ограничениях.
- Стремление к минимальной сложности (бритва Оккама) соответствует поиску программы с минимальной колмогоровской сложностью.

Таким образом, теория индуктивного вывода Соломонова даёт концептуальную основу для понимания возможностей и ограничений нейросетевой генерации кода.